
SYMBOLICKÁ REGRESE PARAMETRŮ GRAVITAČNÍCH VLN

Lukáš Pokorný
FIT CTU
Praha
pokorlu8@cvut.cz

ABSTRACT

Problémem této práce je vytvoření modelu na detekci gravitačních vln, toho bylo dosaženo za pomoci co nejmenších zásahů do dat samotných, jako je filtrace signálů a škálování za pomoci konstant, které souvisí se samotným detektorem vln. Tento model byl dále využit pro data, na kterých se dále udělala symbolická regrese, která spočívá v najití parametrů A_i a ω_i z rovnice $y_i(A_i, \omega_i; t) = A_i \cdot \sin(\omega_i t)$, A_i značí amplitudu, ω_i značí frekvenci a t čas. Data ze symbolické regrese jsou poté využita spolu s výsledkem modelu pro datovou analýzu. Na grafech je není bohužel vidět žádná závislost pravděpodobnost detekce a frekvence, či amplitudy, v závěru jsou poté nastíněny další možnosti práce.

1 Úvod

Gravitační vlny jsou poruchy časoprostoru, které se šíří rychlostí světla a vznikají při pohybu velmi hmotných a urychlených objektů, jako jsou dvojice černých děr nebo neutronových hvězd. Jejich existence byla předpovězena Albertem Einsteinem v rámci obecné teorie relativity již v roce 1916.

Přímá detekce gravitačních vln byla uskutečněna až v roce 2015 experimentem LIGO, který zaznamenal signál ze splnutí dvou černých děr. Tento objev potvrdil platnost obecné teorie relativity v extrémních podmínkách a otevřel novou oblast pozorování vesmíru, to je astronomii gravitačních vln. Gravitační vlny dnes představují důležitý nástroj pro studium kompaktních objektů a dynamiky silných gravitačních polí. První gravitační vlny se detekovaly pomocí jiných gravitačních vln, postupem času se ale vytváří nové metody, například na bázi statistiky, tato práce se zabývá detekcí za pomoci neuronové sítě a snahou pochopit jejich fyzikální základ pomocí symbolické regrese, za pomoci parametrů A_i a ω_i funkce $y_i(A_i, \omega_i; t) = A_i \cdot \sin(\omega_i t)$.

Keywords Gravitační vlny · Symbolická regrese · Neuronová síť

2 Detekce

Práce lze rozdělit na 2 části, první je vytvoření samotného modelu, a druhá poté aplikování symbolické regrese. Výsledek je poté spojen do datové analýzy. Samotné vytváření modelu obsahuje pak analýzu datasetu, přípravu dat na trénování modelu. Najití vhodného modelu pro konkrétní situaci a nakonec trénování, a konečnou validaci.

Načtení dat bylo problémové, protože se 560000 souborů, každý o 3, ze 3 detektorů: LIGO Hanford, LIGO Livingston, Virgo. časových řadách, o 4096 číslech, v řádech $1e - 20$, jen těžko vejde do paměti. Načtení dat je proto za pomoci dictionary soubor:výsledek, kde načtení samotného souboru se provede až, když je potřeba. Toto ještě víc zpomaluje samotné učení. Což může způsobit pomalé učení na slabších počítačích. Proto jsem se rozhodl použít rychlejší model pro fine-tuning dat, ale pro finální model použít model složitější.

Aby byl model vůbec úspěšný je potřeba data zpracovat. Dataset obsahuje 560000 souborů .npz, každý soubor obsahuje 3 časové řady. Každá z jiného konkrétního detektoru. V jejich základní formě data nabývají velmi malých hodnot a jsou plná šumu. Je několik možností, co lze na data aplikovat, aby se tyto problémy vyřešily:




Figure 1: Neupravená časová řada




Figure 2: Řada po aplikaci Butterworth filtru

- **škálování** - data se dostanou do hodnot, se kterými reálně umí počítače samotné pracovat. První a druhý detektor je škálován $1.5e - 20$, třetí detektor je škálován $0.5e - 20$
- **filtrování** - data obsahují hodně šumu, nebo jiných signálů, které nejsou samotný gravitační vlny, jejich odfiltrováním vznikne čistší signál
- **Tukey window** – Tukey window vyhlazuje okraje signálu, aby při výpočtu spektra nevznikaly umělé frekvence. Tím snižuje spektrální únik a zpřesňuje frekvenční analýzu. Spektrální únik je jev, kdy se energie jedné frekvence rozlije do okolních frekvencí, protože analyzovaný signál je časově omezený a má ostré okraje. Ve spektru se pak objeví falešné nebo rozmazané frekvence, které ve skutečném signálu nejsou.




Figure 3: Řada po aplikaci Butterworth filtru a Tukey window




Figure 4: Řada po aplikaci Butterworth filtru, Tukey window a škálování

Problémem použití těchto možností jsem se osobně zabýval nemalý čas. Nakonec jsem ale model naučil na datech co nejméně upravených, ale aby model stále fungoval. Použil jsem tedy škálování a filtrování pomocí Butterworthova filtru. To je typ digitálního nebo analogového filtru, který má co nejhladší frekvenční charakteristiku bez zvlnění v propustném pásmu. Používá se k plynulému potlačení nežádoucích frekvencí (např. šumu) bez výrazného zkreslení amplitudy signálu. Ze signálu je tak odfiltrováno nežádoucí frekvence a zároveň je naškálován na hodnoty, se kterými dokážou počítače pracovat, aniž by celý výpočet nebyl k zahození kvůli numerickým chybám. Pro upřesnění jak moc zpracovat data jsem použil malý model 1D CNN.

Model z této sítě přijímá vstup o třech kanálech a skládá se ze čtyř po sobě jdoucích bloků. Každý blok obsahuje 1D konvoluci, následovanou batch normalizací a aktivační funkcí. Sít' postupně snižuje velikosti konvolučních jader ($k=64,32,16,8$). Redukce dimenzionality je zajištěna vrstvami MaxPool1d po prvních třech blocích. Závěrečný blok využívá globální průměrování k vytvoření vektoru příznaků, který je následně zpracován plně propojenou lineární vrstvou do jediného výstupního neuronu pro klasifikaci. Výhoda této jednodušší sítě je možnost testovat různá zpracování dat, protože učení na této síti je v rámci jednotek hodin, místo jednotek dnů jako u finální sítě. Výsledkem tohoto kroku bylo již jedno zmíněné použití pouze 2 kroků pro zpracování dat. Důvodem bylo použití méně zpracování, aby data jak na samotnou detekci, tak i na symbolickou regresi byla použitelná ve stejném stavu. Použitím Tukeyho okna by se samotná vlna deformovala, proto nebyla pro detekci použita.

Pro finální model byla poté použita sít' na stejné bázi, ale složitější, při učení pak dále bylo použito různých augmentačních technik, jako například posun a prohazování vstupů. To má za úkol, aby se model nenaučil pouze na jeden vstup, a případně snaha zamezit naučení se na chybných datech způsobený použitím filtrů. Konečný model byl pak dále otestován na testovacích datech, kde byla zjištěna $ROC - AUC = 0.8398$, což se od nejlepších výsledků na kaggle soutěži liší pouze v setinách, vzhledem k menšímu zpracování jsem toto viděl jako dobrý výsledek.

3 Symbolická regrese

Tato část se zaměřuje na symbolickou regresi. Jelikož je rovnice, u které chci zjišťovat parametry předem známá, tak není potřeba použít přímo symbolickou regresi, tedy parametry zjišťovat iterativně, například za pomoci genetického algoritmu, což jsem také vyzkoušel, ale vzhledem k obrovskému prostoru možných řešení to bylo pomalé a výsledky byly vizuálně špatné, toto řešení by bylo vhodné, pokud bych měl najít funkci nějakou, či by neexistovaly jednodušší metody, jako je například curve fit, neboli použité nelineárních nejmenších čtverců pro fitování funkce f na data. Zde je ale důležitá jedna úprava a to je přidání parametru ϕ_i , tento parametr slouží jako fázový posun, protože ne každá vlna začíná přesně v 0, tedy málokterá právě začíná v 0, tento parametr je pouze důležitý pro lepší a přesnější výsledky, jeho vrácení nic dalšího nedává. Problém je tedy najít vhodné A_i a ω_i pro rovnici:

$$y_i(A_i, \omega_i; t) = A_i \cdot \sin(\omega_i t + \phi_i)$$

.
Další problém najít tyto parametry je vhodná počáteční hodnota A_i a ω_i . Zatímco pro A_i je tento parametr něco mezi 1 a 0, což není zas tak velké rozpětí a curve_fit je schopný najít dobrou aproximaci při $A_1 = 1$, pro ω_i je větší problém, počáteční odhad velmi ovlivní konečný výsledek. Proto je potřeba najít počáteční odhad ω_i pomocí metody. Na to jsem použil FFT (Fast Fourier Transform), to je rychlý algoritmus, který převádí signál z časové oblasti do frekvenční a umožňuje zjistit, jaké frekvence jsou v signálu obsaženy. To zajistí dobrý počáteční odhad pro ω_i , kde curve_fit zajistí zbytek. Výsledek curve_fit, neboli symbolické regrese je tedy A_i, ω_i , rozptyl odhadů, dále lze dopočítat RMSE odhadů.

Data z detekce a symbolické regrese pak zabalím do datasetu a uložíím ve formátu csv. Takto jsem připravil 3 datasety, liší se tím, jak moc jsou data zpracována pro symbolickou regresi.

- **dataset_1** pro první dataset jsem použil stejné zpracování dat jako pro detekci, je tam tedy nejlepší závislost výsledku modelu a výsledku symbolické regrese
- **dataset_2** druhý dataset obsahuje data, která jsou pouze přeškálovány
- **dataset_3** má navíc oproti prvnímu datasetu data, na které jsem aplikoval Tukey window.

Ve většině případů je použit dataset_1, pokud není explicitně řečeno, důvodem nepoužití jiných datasetů v grafech je takový, že se v datech neobjevovalo nic nového, je tedy zbytečné tyto grafy ukazovat.

4 Výsledky

4.1 Detekce

Výsledek modelu na nových datech je:




Figure 5: Empirická distribuce normalizované amplitudy prvního datasetu (aplikován Butterworth a škálování)

- Validation Accuracy: 0.7769
- F1 score: 0.7269
- ROC-AUC: 0.8398

Pro další výsledky jsem použil zase data, které mdoel při učení neviděl, ta samé data jsem použil jak pro detekci tak pro symbolickou regresi, prvně ale výsledky detekce:

Table 1: Distribuce predikcí přes pravděpodobnost detekce vlny.

Prob Range	Total	True Label	False Label
0.0 – 0.2	15531	3180	12351
0.2 – 0.3	12949	3853	9096
0.3 – 0.4	6160	2486	3674
0.4 – 0.5	3096	1571	1525
0.5 – 0.6	1862	1154	708
0.6 – 0.7	1275	944	331
0.7 – 0.8	1058	852	206
0.8 – 0.9	1121	1002	119
0.9 – 1.0	12948	12906	42

Podle těchto výsledků by se dalo říct, že samotný model má problémy detekovat v rozmezí 0.4-0.6, kde výsledek je až skoro náhodný, to může znamenat, že model samotný má problémy, nebo že data nejsou dostatečně dobrá, jelikož jsou to měření na hraně a model určuje většinu dat správně, lze usoudit, že to jsou slabší gravitační vlny, které obsahují spoustu šumu, který se nemusel odfiltrout. Na toto by ale bylo potřeba víc dat, u kterých víme label, vzhledem k tomu, že jsou data na hraně.

4.2 Symbolická regrese

Výsledek samotné regrese jsou potom grafy závislosti amplitudy na frekvenci, popřípadě empirická distribuce normalizovaných dat. Tyto data jsou vygenerována ze samotné symbolické regrese, a tak k nim není potřeba výstup modelu pro detekci. Zobrazená data jsou pouze z jednoho detektoru, výsledek se ale mezi nima neměnil, kvůli rozsahu samotného souboru jsem tyto grafy nedal do práce.

Z těchto grafů je vidět, že data skutečně mají závislosti, co se týče frekvence a amplitudy, a určitě tam je nějaká závislost na detekci, jelikož bez aplikování Butterworth filtru model neuměl detekovat (vybíral náhodně), hodnoty jsou více kolem jedné hodnoty, to je více vidět u frekvence, otázkou ale je, zda je toto nedokonalostí modelu pro symbolickou regresi (funkce s konstantní frekvencí a amplitudou nedokáže dobře popsat gravitační vlny), nebo nedostatkem dat pro jiné frekvence a amplitudy. Co je ale důležité říct je, že zda je vlna samotná šum, nebo opravdu gravitační vlna nemá vliv na závislost frekvence a amplitudy, obě skupiny se vyskytují na stejných místech.




Figure 6: Empirická distribuce normalizované amplitudy druhého datasetu (škálování), je vidět pravděpodobně neodstraněný šum oproti dataset_1




Figure 7: Empirická distribuce normalizované frekvence prvního datasetu (aplikován Butterworth a škálování)

4.3 Symbolická regrese s detekcí

V této části jsou výsledky detekce spojené s výsledkem symbolické regrese.

Grafy závislosti normalizované amplitudy na pravděpodobnosti a normalizované frekvence na pravděpodobnosti ukazují vytvořený tvar jakési položené vázy. Tento tvar ale je pravděpodobně (práce obsahuje graf odhadu střední hodnoty a variance z dat, která je na celé řadě homoskedastická), důvodem tohoto tvaru tedy je spíš nedostatek dat pro danou pravděpodobnost detekce, než nějaké závislosti.

Graf závislosti amplitudy na frekvenci byl rozšířen ještě o barevné schéma, pravděpodobnosti, že je vlna gravitační vlna. Stejně jako u samotné symbolické regrese zde není vidět závislost amplitudy, či frekvence na pravděpodobnosti detekce.

Odhad střední hodnoty a variance. Pro všechny datasety je stejná, odhady jsou homoskedastické a mají stejnou hodnotu.

Poslední graf je poté naměřená chyba vs pravděpodobnost, stejný tvar jako u amplitudy a frekvence, zase pravděpodobně z nedostatku dat pro danou pravděpodobnost.

5 Závěr

I přes to, že práce úspěšně obsahuje jak detekci, tak i najití parametrů A_i a ω_i , je závěr práce negativní. V datech jsem osobně nenašel závislost detekci na amplitudě, či frekvenci. Odhady středních hodnot a variancí tento závěr potvrzují.




Figure 8: graf závislosti normalizované amplitudy na normalizované frekvence prvního datasetu




Figure 9: Grafy normalizované amplitudy a normalizované frekvence na pravděpodobnosti detekce




Figure 10: graf závislosti normalizované amplitudy na normalizované frekvence prvního datasetu s barevným schématem podle pravděpodobnosti detekce




Figure 11: Odhad střední hodnoty a variance normalizované amplitudy a frekvence se závislostí na pravděpodobnosti detekce




Figure 12: závislost RMSE na pravděpodobnosti detekce

Pro úplné potvrzení by byla potřeba spoustu nových dat, samotná soutěž už je několik let stará a za tu dobu proběhlo spoustu výzkumu, co se týče gravitačních vln. Pokud by ani nová data neprokázala závislost, ještě je tu možnost nějaké lepší rovnici pro vysvětlení gravitačních vln. Na internetu se takové jiné možnosti objevují, problém je ale ve výstupu těchto funkcí, v případě téhle práce jsou pouze 2, jiné funkce můžou mít spoustu parametrů, které se poté obtížně interpretují, bylo by tedy potřeba najít rovnováhu mezi schopností funkce vysvětlovat gravitační vlny a její interpretací pro následnou analýzu.

6 Odkazy

6.1 Data

<https://www.kaggle.com/competitions/g2net-gravitational-wave-detection/data>

6.2 Kód

<https://gitlab.fit.cvut.cz/pokorlu8/mvi-sp>

6.3 Zdroje

<https://www.kaggle.com/competitions/g2net-gravitational-wave-detection/leaderboard>

<https://www.kaggle.com/competitions/g2net-gravitational-wave-detection/writeups/kdl-top-1-solution-deep-learning-part>

<https://www.kaggle.com/code/firefliesqn/g2net-gpu-newbie>

<https://iopscience.iop.org/article/10.1088/1361-6382/ab685e>

<https://gwpv.github.io/docs/3.0.12/>

<https://www.kaggle.com/competitions/g2net-gravitational-wave-detection>